

Na podstawie nowo przesłanych prezentacji z wykładów (z serii **DL – Deep Learning** prowadzonych przez Wojciecha Palubickiego), poniżej znajduje się synteza najważniejszych pojęć, architektur i zagadnień niezbędnych na egzamin.

I. Wprowadzenie do Sztucznej Inteligencji i Klasyfikacji Obrazów

- **Definicje sztucznej inteligencji:**
 - **Sztuczna Inteligencja (AI):** Dowolna technika umożliwiająca komputerom naśladowanie ludzkiej inteligencji (logika, reguły if-then, drzewa decyzyjne, uczenie maszynowe).
 - **Uczenie Maszynowe (ML):** Podzbiór AI obejmujący techniki statystyczne, które pozwalają maszynom ulepszać wykonywanie zadań wraz z nabywanym doświadczeniem.
 - **Głębokie Uczenie (DL):** Podzbiór uczenia maszynowego oparty na wielowarstwowych sieciach neuronowych (Multilayer Neural Networks) trenowanych na ogromnych ilościach danych.
- **Zadania Computer Vision (Wizji Komputerowej):**
 - **Klasyfikacja obrazu (Image Classification):** Przypisanie jednej etykiety z zamkniętego zbioru do całego obrazu (np. "kot"). Brak informacji o położeniu przestrzennym obiektu.
 - **Segmentacja semantyczna (Semantic Segmentation):** Klasyfikacja każdego pojedynczego piksela na obrazie do danej kategorii (np. trawa, niebo, kot).
 - **Detekcja obiektów (Object Detection):** Znalezienie obiektów na obrazie, przypisanie im etykiety klasy oraz wyznaczenie tzw. *Bounding Box* (ramki otaczającej).
 - **Segmentacja instancji (Instance Segmentation):** Detekcja obiektów połączona z dokładnym wyznaczeniem maski pikseli dla każdego wykrytego obiektu z osobną (rozdziela dwa osobne obiekty tej samej klasy, np. "pies 1" i "pies 2").

II. Klasyfikatory liniowe i funkcje kosztu (Loss Functions)

- **Klasyfikator K-Najbliższych Sąsiadów (K-NN / Nearest Neighbor):**
 - *Faza trenowania:* Zapamiętanie wszystkich danych i ich etykiet ($O(1)$).
 - *Faza predykcji:* Znalezienie najbardziej podobnego przykładu i przypisanie jego etykiety ($O(N)$ – bardzo wolne podczas testowania). Granice decyzyjne mogą być zaszumione przez wartości odstające (*outliers*).
- **Podejście parametryczne (Linear Classifier):**
 - Funkcja przyjmuje postać $f(x, W) = Wx + b$. Mapuje piksele obrazu wejściowego x na surowe wyniki klas (tzw. scores) za pomocą macierzy wag W i wektora obciążenia (*bias*) b .
 - *Ograniczenia:* Klasyfikator liniowy uczy się tylko jednego szablonu ("template") per klasa i nie potrafi poprawnie separować danych, których nie da się rozdzielić hiperpłaszczyzną.
- **Funkcje kosztu (Loss Functions):**
 - **Hinge Loss (Multiclass SVM Loss):** Wylicza błąd na podstawie założeń, że poprawna klasa powinna mieć wynik wyższy od klas niepoprawnych o ustalony margines (zazwyczaj 1).
$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$
 - **Softmax Loss (Cross-Entropy Loss / Multinomial Logistic Regression):** Interpretuje

surowe wyniki z sieci jako nieznormalizowane logarytmy prawdopodobieństwa. Funkcja Softmax przekształca je w rozkład prawdopodobieństwa, a celem jest minimalizacja ujemnego logarytmu prawdopodobieństwa poprawnej klasy.

$$L_{-i} = -\log\left(\frac{e^{s_{y_{-i}}}}{\sum_j e^{s_{j}}}\right)$$

III. Wielowarstwowy Perceptron (MLP) i Optymalizacja

- **Multi-Layer Perceptrons (MLP):** Wprowadzają nieliniowość poprzez nakładanie warstw ukrytych. Podstawowa sieć dwuwarstwowa ma postać: $f = W_2 \cdot \max(0, W_1 x)$, gdzie funkcją nieliniową (aktywacji) jest np. **ReLU** ($\max(0, z)$).
- **Optymalizacja:**
 - **Stochastic Gradient Descent (SGD):** Uaktualnianie wag poprzez kroczenie w kierunku przeciwnym do gradientu funkcji błędu obliczonego dla losowej mini-paczki danych.
 - **Algorytm Adam:** Bardzo popularny, domyślny algorytm optymalizacji pierwszego rzędu łączący zalety SGD z momentum oraz adaptacyjnym dopasowywaniem współczynnika uczenia (*learning rate*).

IV. Konwolucyjne Sieci Neuronowe (CNN)

Sieci CNN dedykowane do przetwarzania obrazów składają się z trzech głównych komponentów:

1. **Warstwy splotowe (Convolution Layers):** Wykonują operację 2D konwolucji (splotu) obrazu wejściowego z zestawem uczonych filtrów (jąder/kernels), generując mapy cech (*feature maps*). Filtry te wychwytyją lokalne wzorce przestrzenne (krawędzie, kształty).
 2. **Warstwy łączące (Pooling Layers):** Służą do redukcji wymiarowości przestrzennej (downsampling, np. Max Pooling), co zmniejsza liczbę parametrów i zapewnia częściową niezmienniczość na przesunięcia.
 3. **Warstwy w pełni połączone (Fully-Connected / Dense Layers):** Umieszczane na końcu sieci w celu dokonania ostatecznej klasyfikacji na podstawie spłaszczonych cech.
- **Funkcja aktywacji i normalizacja:** Pomiędzy warstwami stosuje się funkcje nieliniowe (np. ReLU) oraz warstwy normalizacyjne (np. *Layer Normalization* lub *Batch Normalization*) w celu stabilizacji procesu uczenia.

V. Sieci Rekurencyjne (RNN) i Mechanizmy Atencji

- **Sieci Feedforward vs RNN:** Klasyczne sieci feedforward przetwarzają stały rozmiar wejścia na stały rozmiar wyjścia (one-to-one). Sieci rekurencyjne (**RNN**) są zaprojektowane do przetwarzania sekwencji o zmiennej długości dzięki posiadaniu tzw. stanu wewnętrznego (*internal hidden state* h_t), który jest aktualizowany w każdym kroku czasowym:
$$h_t = f(W)(h_{t-1}, x_t)$$
- **Typy architektur sekwencyjnych (RNN):**
 - *One-to-many:* Np. podpisywanie zdjęć (*Image Captioning* – wejściem jest obraz, wyjściem sekwencja słów).
 - *Many-to-one:* Np. klasyfikacja wideo (wejściem sekwencja klatek, wyjściem jedna

- etykieta).
- *Many-to-many*: Np. tłumaczenie maszynowe (*Machine Translation* – sekwencja słów w jednym języku na sekwencja w drugim).
- **Mechanizm Atencji (Attention)**: Wprowadzony pierwotnie do modeli RNN, aby umożliwić sieci bezpośrednie "spoglądanie" na różne, kluczowe części wejścia w każdym kroku generowania wyjścia.
- **Transformer**: Architektura sieci neuronowych, która całkowicie rezygnuje z rekurencji (RNN) na rzecz uogólnionego mechanizmu własnej atencji (*Generalized Self-Attention*), co pozwala na pełne zrównoleglenie obliczeń.

VI. Zaawansowana Detekcja Obiektów i Segmentacja

- **Zadanie detekcji (Object Detection)**: Wejściem jest obraz RGB, a wyjściem zestaw wykrytych obiektów (klasa + 4 współrzędne ramki: $x, y, \text{width}, \text{height}$). Wyzwanie stanowi zmienna liczba obiektów na jednym zdjęciu oraz konieczność jednoczesnej klasyfikacji i regresji ramki.
- **Ewolucja modeli z rodziny R-CNN (Region-based CNN)**:
 - **"Slow" R-CNN**: Wybiera z obrazu ok. 2000 regionów próbnych (propozycji), a następnie przepuszcza każdy z tych wyciętych obrazków niezależnie przez sieć CNN (ogromny koszt obliczeniowy).
 - **Fast R-CNN**: Przepuszcza cały obraz przez sieć CNN tylko raz, otrzymując globalną mapę cech. Wycinanie propozycji regionów (cropping) odbywa się w sposób różniczkowalny bezpośrednio na poziomie wyekstrahowanych cech.
 - **Faster R-CNN**: Całkowicie integruje proces generowania propozycji za pomocą wbudowanej podsieci **RPN** (*Region Proposal Network*) operującej bezpośrednio na cechach z sieci bazowej (*Backbone*).
 - **Mask R-CNN**: Rozszerzenie architektury Faster R-CNN o dodatkową, równoległą gałąź (głowicę) przewidującą maskę pikseli dla każdego obiektu, realizując w ten sposób zadanie segmentacji instancji (*Instance Segmentation*).