

Filip Graliński

Regresja logistyczna


Regresja liniowa – podsumowanie

Regresja liniowa to najprostszy możliwy model:

- im czegoś więcej na wejściu, tym proporcjonalnie (trochę) więcej/mniej na wyjściu
- nic prostszego nie da się wymyślić (funkcja stała?? LOL)
- niestety model liniowy czasami kompletnie nie ma sensu (np. wzrost człowieka w stosunku do wieku)

To teraz do regresji **logistycznej**, prowadzą tam dwie drogi:

- 1 od naiwnego Bayesa
- 2 od klasyfikacji liniowej



od naiwnego Bayesa do regresji logistycznej

Policzmy logarytm **szans**, że tekst q należy do klasy c (np. że jest spamem). (Szanse to stosunek prawdopodobieństwa zajścia czegoś do prawdopodobieństwa niezajścia). Oznaczmy przez x_i liczbę wystąpień termu t_i w tekście q , teraz:

$$\begin{aligned}\log \frac{P(c|q)}{P(\bar{c}|q)} &= \log \frac{P(c)P(q|c)}{P(\bar{c})P(q|\bar{c})} = \log \frac{P(c) \prod_i P(t_i|c)^{x_i}}{P(\bar{c}) \prod_i P(t_i|\bar{c})^{x_i}} = \\ &= \log \left(\frac{P(c)}{P(\bar{c})} \prod_i \frac{P(t_i|c)^{x_i}}{P(t_i|\bar{c})^{x_i}} \right) = \log \left(\frac{P(c)}{P(\bar{c})} \prod_i \left(\frac{P(t_i|c)}{P(t_i|\bar{c})} \right)^{x_i} \right) = \\ &= \log \frac{P(c)}{P(\bar{c})} + \sum_i x_i \log \frac{P(t_i|c)}{P(t_i|\bar{c})}\end{aligned}$$

od naiwnego Bayesa do regresji logistycznej (cd.)

... weźmy teraz $w_0 = \log \frac{P(c)}{P(\bar{c})}$, $w_i = \log \frac{P(t_i|c)}{P(t_i|\bar{c})}$ i mamy:

$$\log \frac{P(c|q)}{P(\bar{c}|q)} = w_0 + \sum_i w_i x_i = w_0 + w_1 x_1 + \dots + w_k x_k$$

A zatem sprowadziliśmy naiwnego Bayesa do liniowej formuły!

(Wagi nie są odbierane „optymalnie”, lecz na podstawie idiot-modelu, który w praktyce działa całkiem nieźle.)

„Optymalne” dobieranie wag to **regresja logistyczna**!


od naiwnego Bayesa do regresji logistycznej

Jeszcze popatrzymy na lewą stronę, logarytm szans:

$$\log \frac{P(c|q)}{P(\bar{c}|q)} = \log \frac{P(c|q)}{1 - P(c|q)} = \text{logit}(P(c|q))$$

gdzie „logit” to **funkcja logitowa**:

$$\text{logit}(x) = \log \frac{x}{1 - x}$$



Funkcja logitowa rozciąga wartości $[0, 1]$ (np. prawdopodobieństwa) do $[-\infty, +\infty]$.


od regresji liniowej do logistycznej

No to spróbujmy inaczej.

Dlaczego nie zastosować regresji liniowej do klasyfikacji?

Powiedzmy, że $y = 1$ to spam, a $y = 0$ — nie-spam. . .

NIE, to jest głupie! Regresja liniowa nie „lubi” ograniczonych wartości y



od regresji liniowej do logistycznej

- 1 Przepuścić prawdopodobieństwa przez logit.
- 2 Zastosować regresję liniową, by ustalić wagi w_i .
- 3 Odgadywać przez zastosowanie odwróconego logitu.

od regresji liniowej do logistycznej

- 1 Przepuścić prawdopodobieństwa przez logit.
- 2 Zastosować regresję liniową, by ustalić wagi w_i .
- 3 Odgadywać przez zastosowanie odwróconego logitu.
- 4 PROFIT!

od regresji liniowej do logistycznej

- 1 Przepuścić prawdopodobieństwa przez logit.
- 2 Zastosować regresję liniową, by ustalić wagi w_i .
- 3 Odgadywać przez zastosowanie odwróconego logitu.
- 4 PROFIT!

Nie tak szybko! Niestety wszystkie przykłady uczące mają albo $y = 0$, albo $y = 1$, a zatem albo $\text{logit}(y) = -\infty$, albo $\text{logit}(y) = +\infty$.

Normalna regresja liniowa uczona na wartościach nieskończonych – niedobrze. . .

Przeddefiniujemy problem

- nasz klasyfikator będzie zwracał prawdopodobieństwo, nie wartości 0/1
 - w sumie słusznie, nie jesteśmy Duchem Św., żeby twierdzić coś na pewno jest albo nie jest
- minimalizujemy log-loss (nie błąd kwadratowy)

$$\text{logloss} = -\frac{1}{n} \sum_{i=1}^n (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

- jeśli chcesz zwracać $p_i = 0$ albo $p_i = 1$, to radzę być pewnym!


od regresji liniowej do logistycznej

Jednostka dokonująca regresji logistycznej:

$$\hat{p} = \text{logit}^{-1}\left(w_0 + \sum_{i=1}^k w_i x_i\right)$$


Czyli: najpierw liniowo, a potem nieliniowo.

A tak wygląda logit^{-1} :



(Ścisła całą oś w przedział (0, 1).)

od regresji liniowej do logistycznej



od regresji liniowej do logistycznej

Jak uczyć regresję logistyczną? Wzoru (z odwracaniem macierzy) podanego wcześniej nie da się już w ogóle zastosować (nieskończoności!)

-
- 1: Zaczynij od byle jakich wag w_i (np. wylosuj)
 - 2: **repeat**
 - 3: Weź losowy przykład uczący $x_1, \dots, x_n, y$.
 - 4: Oblicz wyjście $\hat{y}$ na podstawie $x_1, \dots, x_n$.
 - 5: Oblicz funkcję błędu między y a $\hat{y}$.
 - 6: Zmodyfikuj lekko wagi w_i w kierunku spadku funkcji błędu.
 - 7: **until** Błąd stanie się wystarczająco mały
-

$$w_i := w_i - x_i(\hat{y} - y)\eta$$

(To nie jest błąd *copy and paste*!)